

基于检索增强生成与引力模型的用户移动行为预测

刘博¹⁾²⁾ 李桐¹⁾²⁾ 肖竹^{1)2)*} 唐卓¹⁾²⁾ 李肯立¹⁾²⁾

¹⁾(湖南大学计算机学院, 长沙410082)
²⁾(湖南大学国家超级计算长沙中心, 长沙410012)

摘 要 移动行为预测对城市交通调度、位置推荐及应急管理具有核心支撑作用。现有基于大语言模型 (LLMs) 的预测方法主要依赖模型的参数化记忆, 难以显式捕捉历史数据中的统计特征与移动规律; 同时, 由于缺乏空间感知能力, LLMs 无法有效建模物理空间的距离约束与区域吸引力。针对上述挑战, 本文提出一种融合移动行为知识检索与空间引力建模的预测框架RAG²-MP。该框架在推理过程中通过检索行为模式知识构建群体先验, 并利用改进的引力模型引入空间相互作用约束, 最终由LLM统一整合多源信息实现精准预测。在三个大规模真实世界数据集上的实验结果表明, RAG²-MP在 $Acc@1$ 、 $Acc@5$ 、 $MRR@5$ 和 ADE 指标上较最先进基线模型分别平均提升了10.02%、11.32%、8.91%和9.41%, 充分验证了该框架的有效性与鲁棒性。

关键词 移动行为预测; 大语言模型; 检索增强生成; 引力模型
中图法分类号 TP DOI号: *投稿时不提供DOI号

A Mobility Prediction Method Based on Retrieval-Augmented Generation and Gravity Model

LIU Bo¹⁾²⁾ LI Tong¹⁾²⁾ XIAO Zhu¹⁾²⁾ TANG Zhuo¹⁾²⁾ LI Kenli¹⁾²⁾

¹⁾(College of Computer Science and Electronic Engineering, Hunan University, Changsha 410082, China)
²⁾(National Supercomputing Center in Changsha, Hunan University, Changsha 410012, China)

Abstract. Mobility behavior prediction plays a pivotal role in urban traffic scheduling, location recommendation services, and emergency management. Existing prediction methods based on Large Language Models (LLMs) are difficult to explicitly capture statistical features and mobility patterns from historical data and fail to effectively model physical distance constraints and regional attractiveness. To address these challenges, this paper proposes RAG²-MP, a prediction framework that integrates knowledge retrieval of mobility behavior with spatial gravity modeling. During inference, the framework constructs collective priors by retrieving behavioral pattern knowledge and incorporates spatial interaction constraints via an improved gravity model. Finally, the LLM unifies and integrates multi-source information to achieve accurate predictions. Experimental results on three large-scale real-world datasets demonstrate that RAG²-MP outperforms state-of-the-art (SOTA) baselines, achieving average improvements of 10.02%, 11.32%, 8.91%, and 9.41% in $Acc@1$, $Acc@5$, $MRR@5$, and ADE , respectively, validating the effectiveness and robustness of the proposed framework.

Keywords Mobility Prediction; Large Language Models; Retrieval-Augmented Generation; Gravity Model

收稿日期: - - ; 最终修改稿收到日期: - - . *投稿时不填写此项*. 本课题得到国家自然科学基金(U24A20247, 62471277)、中国科协青年人才托举工程(ZB2025-29)资助。刘博, 性别, 2001年生, 硕士研究生, 主要研究领域为空间智能、大模型智能体。E-mail: liubo317@hnu.edu.cn. 李桐 (通信作者), 男, 1992年生, 博士, 教授, 是计算机学会(CCF)会员 (83730M), 主要研究领域为空间智能、大模型智能体。E-mail: tliay@hnu.edu.cn. 肖竹 (通信作者), 男, 1981年生, 博士, 教授, 是计算机学会(CCF)会员 (19010S), 主要研究领域为智能交通、时空数据挖掘。E-mail: zhuxiao@hnu.edu.cn. 唐卓, 男, 博士, 教授, 是计算机学会(CCF)会员, 主要研究领域为分布式计算系统、大数据并行处理、分布式机器学习和安全模型。E-mail: ztang@hnu.edu.cn. 李肯立, 男, 博士, 教授, 是计算机学会(CCF)会士, 主要研究领域为并行计算、云计算和大数据计算。E-mail: lkl@hnu.edu.cn. 第2作者手机号码(15073197902)。

1 引言

随着移动互联网基础设施的普及与多维位置感知技术的演进,人类移动行为预测已成为支撑个性化位置服务、智慧交通管理以及突发公共卫生事件预测的核心基石[1-3]。该任务旨在通过深度建模用户历史轨迹序列,解析其蕴含的深层移动意图与出行决策逻辑,从而为城市复杂系统的资源调度与决策优化提供科学依据。近年来,移动行为预测范式经历了从统计表征到生成建模的显著演进。早期研究主要聚焦于序列建模,利用循环神经网络或自注意力机制捕捉轨迹中的长短期时序依赖,以表征人类移动的时空动态规律[4-6]。随后,为打破“时空孤岛”效应,研究者开始引入多源上下文信息,通过融合时间周期性、兴趣点(POI)属性及用户画像等外部语境,增强模型对异构出行环境的感知深度。为进一步刻画城市空间实体间的复杂拓扑关系,基于图神经网络(GNN)方法应运而生,通过构建区域交互图或POI关联图,有效建模了跨区域迁移过程中的空间相关性[7]。

随着大语言模型(Large Language Models, LLMs)在自然语言处理领域展现出卓越的生成能力与上下文推理潜力,研究人员开始探索将其应用于移动行为预测等时空建模任务[8,9]。相较于侧重统计规律拟合的传统模型及依赖数值特征映射的深度学习方法,LLMs凭借其深厚的语义常识与逻辑推理能力,能够从更高维度解析人类移动行为背后的深层意图与决策动机。例如,LLM-ZS[10]利用零样本(Zero-shot)推理在稀疏标注场景下推断移动意图;LLM-COD[11]通过引入结构化上下文约束增强了预测的一致性;AgentMove[12]则构建了智能体代理机制以模拟个体层面的出行决策过程。这些前期工作表明,移动行为预测正被重新定义为一种基于自然语言的情境理解与序列推理问题。然而,现有的基于LLM的移动预测方法仍面临两大核心挑战:(1)参数化记忆的封闭性与知识检索能力的缺失。现有方法主要依赖LLMs在预训练阶段内化的静态参数化记忆进行推理。其对移动行为模式的理解以分布式表征形式隐式地蕴含于模型权重中,缺乏可组织、可调用的显式结构化知识形态[13,14]。事实上,处于相似情境下的历史轨迹在语义空间中往往呈现出一致的结构特征,反映了稳定的移动规律。由于缺乏以行为模式为单元的知识表征与检索机制,现有模型难以在推理过程中主动关联并调用历史情境中的先验经验,导致预测过程过度依赖概率性的隐式生成。这种推理机制的黑盒特性使得模型在面对复杂情境或分布偏移时,难以保持输出的稳定性与鲁棒性。(2)文本表征与物理空间感知之间的鸿沟。尽管LLMs具

备强大的文本语义建模能力,但其本质上缺乏对真实物理空间维度的具身感知。空间距离、区域吸引力及地理可达性等关键时空约束在当前的纯文本提示框架下,往往缺乏显式的物理建模与量化表达。因此,模型在预测时难以准确权衡地理位置的物理合理性,亦无法刻画不同功能分区对移动行为的引力强度。这导致模型容易生成语义合理但物理不可行的预测结果,这种空间感知的缺失严重制约了基于LLMs的移动预测在城市安全与精密调度等严肃场景中的可靠性。

本文提出一种融合行为模式知识检索与物理空间结构约束的移动预测框架RAG²-MP。该框架旨在打破LLM单一的参数驱动生成范式,通过在推理过程中引入群体行为模式先验与空间相互作用约束,实现知识驱动与物理感知的统一建模。首先,针对情境知识缺失导致的推理不稳定性,RAG²-MP构建了一种基于检索增强的行为模式显式引入机制。该机制以当前轨迹情境为查询条件,从高维历史轨迹空间中检索并识别语义及结构相似的典型出行模式。通过将这些实例级的行为模式转化为可理解的结构化知识表示,并将其动态注入LLM的上下文,本框架实现了从隐式参数记忆向显式模式引导的推理方法转变。这种设计使得模型能够基于历史经验进行逻辑对齐,显著增强了其在复杂、多变情境下的预测鲁棒性。其次,针对物理空间感知匮乏的问题,本文引入改进的引力模型作为底层的空间结构约束。该模型通过联合表征目标区域内的兴趣点分布特征与地理距离衰减关系,量化地刻画了不同功能区域对移动行为的吸引力强度,从而构建起空间相互作用的先验分布。这一物理约束被显式地集成至LLM的候选位置评估流程中,为预测结果提供了地理层面的可行性过滤与排序依据。

本文的主要贡献可归纳为以下三个方面:

(1) 本文讨论了现有基于大语言模型的移动预测方法的局限性,并构建了标准化的轨迹检索知识库。研究不仅揭示了静态参数记忆的不足,还通过实证分析验证了检索增强机制的扩展性,即通过跨城市共享与扩展知识库规模,能够显著增强大语言模型的预测表现。(2) 本文提出一种基于知识增强与空间结构约束协同建模的移动预测框架。该框架在推理阶段引入情境行为模式知识,使预测过程能够显式参考实例层经验;同时结合空间相互作用规律构建结构先验,对生成结果施加可量化的空间一致性约束。通过在知识层与结构层形成双重约束机制,模型由单一的参数驱动生成扩展为知识引导与结构校准协同的推理过程。(3) 本文在涵盖不同城市规模与移动类型的三个真实数据集上进行了广泛且全面的实验。实验结果表明,所提模型在准

确率和空间一致性上显著优于现有的最先进基线模型, 并展现出强大的跨城市泛化能力。

2 相关研究

2.1 统计与深度学习驱动的移动行为预测方法

早期移动行为预测研究主要植根于概率统计与物理启发式建模。其中, 引力模型 (Gravity Model) [15–18]通过解构区域吸引力与距离衰减函数, 奠定了空间交互建模的基础。后续研究通过参数自适应优化 [19]提升了模型对特定数据分布的拟合能力与可解释性。与此同时, 基于马尔可夫假设的序列模型亦得到广泛应用, 如FPMC [20]通过耦合个性化偏好与一阶状态转移, 有效捕捉了短期移动规律, 成为该领域的经典基线。随着深度学习的兴起, 研究重心转向了基于神经网络的表示学习。以DeepMove [21, 22]为代表的模型利用循环神经网络 (RNN) 与注意力机制, 实现了对长短期行为偏好的联合表征。为进一步强化空间维度的建模, 时空图神经网络 (STGNN) [23]及其超图变体 [24, 25]通过显式刻画位置间的拓扑关系与高阶时空依赖, 显著提升了预测精度。然而, 此类方法普遍将轨迹视为离散的ID序列, 缺乏对移动意图与环境语义的深层分析。尽管传统模型与深度学习在挖掘显式时空依赖方面表现出色, 但在应对数据稀疏与语义理解方面仍存在瓶颈。一方面, 现有方法难以处理缺乏充足轨迹支撑的冷启动问题; 另一方面, 它们未能充分激活海量历史轨迹中蕴含的群体共性知识。鉴于此, 本文提出利用LLMs的语义推理能力, 并结合检索增强生成技术, 通过检索群体历史行为模式作为显式知识上下文。该方案旨在弥补纯数值拟合的不足, 在语义推理与数据驱动之间寻求平衡, 实现更高维的移动意图理解。

2.2 基于大语言模型移动行为预测方法

近年来, 大语言模型 (LLM) 的兴起为移动行为预测提供了新的研究思路。相关研究通过将轨迹序列转化为自然语言描述, 将移动预测建模为语义推理任务, 从而充分利用大语言模型在常识推理与上下文关联方面的优势 [26]。LLM-ZS [10]首次系统性验证了预训练大语言模型在零样本条件下执行下一位置预测的可行性, 展示了其在冷启动场景中的潜力。随后, LLM-COD [11]进一步引入结构化上下文条件, 并在候选位置集合上执行约束解码, 以提升预测的稳定性与可控性。在此基础上, 一些研究开始探索更复杂的推理机制。例如, AgentMove [12]将移动行为预测建模为基于大语言模型智能体的决策过程, 这类方法在推理灵活性方面具有优势, 但整体仍主要依赖大语言模型的内部参数记忆进行决策。此外, 现有基于LLM的方

法普遍缺乏对物理空间结构的显式建模。由于大语言模型的推理过程主要发生在离散语义空间中, 地理距离、区域可达性与空间吸引力等连续空间约束往往难以得到有效表达, 容易导致语义合理但地理上不可行的预测结果。

3 移动行为预测问题定义

移动行为预测旨在利用用户历史移动轨迹数据, 预测用户在下一时刻可能访问的地理位置。该任务不仅需要建模用户个性化的移动偏好 (如通勤习惯、常访地点), 还需考虑地理环境的空间约束 (如距离、区域功能) 以及群体行为的共性特征。具体而言, 将移动行为预测问题形式化定义如下:

定义1 (位置). 位置 l 被定义为城市划分后的地理网格ID (Location ID), 属于位置集合 $\mathcal{L}$ 。每个位置包含地理语义信息 $\mathcal{G} = \{(\text{coord}_l, \mathcal{P}_l) | l \in \mathcal{L}\}$, 其中 coord_l 表示位置 l 的地理坐标, $\mathcal{P}_l$ 表示位置 l 的区域功能语义。

定义2 (轨迹). 用户 u 的观测轨迹序列定义为 $\mathcal{S}_u = \{(l_1, t_1), (l_2, t_2), \dots, (l_x, t_x)\}$, 其中 (l_i, t_i) 表示用户在时间戳 $t_i \in \mathcal{T}$ 访问了位置 $l_i \in \mathcal{L}$, 且 $t_1 < t_2 < \dots < t_x$ 。

定义3 (兴趣点). 兴趣点 (Point of Interest, POI)是具有特定功能的地理实体, $\mathcal{P}_l$ 表示位置 l 内各类POI的数量构建分布向量, 提供区域功能的语义信息。

定义4 (检索知识库). 轨迹检索知识库定义为 $\mathcal{R} = \{\mathcal{S}_v | v \in \mathcal{U}_{rag}\}$, 包含了用于构建库的用户历史轨迹数据。

定义5 (移动行为预测). 本研究的目标是利用大语言模型 (LLM) 处理轨迹序列和检索到的上下文信息, 结合地理引力特征, 生成下一时刻的位置预测。即给定用户 u 的历史轨迹序列 $\mathcal{S}_u$, 结合轨迹检索知识库 $\mathcal{R}$ 以及全局地理语义信息 $\mathcal{G}$, 建立一个映射函数 f , 预测用户在未来时刻 t_{n+1} 将要访问的位置 $l_{n+1} \in \mathcal{L}$ 。数学表达如下:

$$f : (\mathcal{S}_u, \mathcal{R}, \mathcal{G}) \rightarrow \hat{l}_{x+1}. \quad (1)$$

4 RAG²-MP模型

本节将详细阐述所提出RAG²-MP模型的整体架构及各个核心组成部分的设计细节。

4.1 模型整体框架

本文提出一种基于情境知识增强与空间结构约束协同建模的移动预测框架RAG²-MP。如图1所示, RAG²-MP在推理阶段引入行为模式知识, 以提供实例层经验支撑; 同时结合空间相互作用规律构建结构先验, 对生成结果施加可量化的空间一致性约束, 从而在知识与结构双重引导




图1 基于情境知识增强与空间结构约束协同建模的移动预测框架RAG²-MP，通过知识检索增强模块从历史轨迹中构建情境相似的群体行为模式，并结合引力模型刻画空间相互作用关系，在LLM统一推理下协同融合情境知识与空间结构约束，实现对下一位置的语义合理且空间一致的移动行为预测




图2 群体移动行为知识库构建，群体移动轨迹经语义抽象、LLM编码与密度聚类后，形成行为模式并构建移动行为知识库

下完成预测。知识检索增强 (Retrieval-Augmented Generation, RAG) 模块负责构建情境行为模式知识。该模块以当前轨迹情境为条件，从历史数据中识别结构相似的群体移动模式，并形成可结构化的知识表示融入推理流程。通过显式引入群体层行为经验，模型能够在预测阶段参考群体模式规律。引力搜索模块则提供空间结构层约束。基于空间相互作用理论，模块计算当前位置与候选地点之间的引力强度，将其作为衡量空间可达性与吸引关系的结构指标，对语义生成结果进行空间一致性筛选与校准。该机制确保预测结果在满足语义合理性的同时符合地理结构规律，从而形成可量化的空间约束。最终，LLM模块作为统一的推理与决策核心，对情境知识与空间结构信息进行协同分析，完成下一位置预测。整体框架在知识层、结构层与语义推理层形成协同机制，实现经验支撑、空间约束与语义理解的统一。

4.2 检索增强模块

检索增强生成 (Retrieval-Augmented Generation, RAG) 模块旨在利用大规模历史

轨迹数据作为外部知识库，突破单一用户历史数据稀疏性的局限，从群体层面的共性行为中挖掘出深层次的移动规律与时空语义特征。传统预测方法往往受限于目标用户有限的历史记录，面临冷启动或长尾模式的挑战。单一用户的数据稀疏性使得模型难以捕捉低频但重要的出行规律。为此，如图2所示，检索增强模块的整体流程包括移动行为知识库构建和移动行为模式知识检索两个部分。通过将相似用户的历史经验转化为当前预测任务的高质量辅助上下文信息，实现跨用户的知识迁移与共享。

4.2.1 移动行为知识库构建

移动行为知识库 R 的构建旨在从群体历史轨迹中提炼出具有代表性的移动行为模式，为后续检索与推理提供结构化知识支撑。原始轨迹数据规模庞大且存在显著冗余，若直接作为检索对象不仅会降低效率，也难以突出行为模式的结构特征。因此，本文通过语义编码、模式聚类与代表性采样等步骤，对历史轨迹进行分层组织与模式级抽象，构建紧凑而具有表达能力的知识库。首先，对历史轨迹序列的移动模式进行文本化表示。基于统一的自然语言模板 $\text{Prompt}(\cdot)$ ，将具体的时空轨迹转换为包含时间结构、空间转移与POI功能语义的移动行为描述，例如“用户在上午09:00从运动区出发，移动三公里到达办公”等文本形式。该过程将离散轨迹映射为可被大语言模型理解的语义表达。随后，利用预训练LLM编码器将轨迹描述映射至高维语义空间，得到对应的嵌入表示：

$$e_u = \text{LLM}_{enc}(\text{Prompt}(S_u)). \quad (2)$$

通过该方式，不同移动意图或功能结构相似的轨迹将在语义空间中呈现相邻分布。在嵌入空间中，

利用HDBSCAN算法对轨迹向量进行密度聚类, 得到 K_c 个移动行为模式簇 $\{C_1, C_2, \dots, C_{K_c}\}$ 。每个簇对应一种结构相似的移动模式, 如稳定通勤模式、周期性休闲模式或探索性出行模式等。针对聚类结果, 为从每类模式中提取具有代表性的知识载体, 本文在簇内部设计了“中心-边缘”混合采样策略。根据样本嵌入向量与由簇内嵌入向量均值确定的簇中心之间的距离进行采样, 选取距离最小的典型样本刻画模式核心结构, 同时抽取距离较远但仍属于该簇的边缘样本, 以保留模式内部的结构变体与长尾形态。最后, 利用LLM对采样得到的模式样本进行高层次语义总结, 生成概括性的行为模式文字描述。每个模式簇最终由三类信息构成: 代表性样本集合、平均语义嵌入向量以及移动行为语义描述。上述信息共同构成知识库中的一条结构化记录, 所有模式记录汇总形成移动行为知识库 $\mathcal{R}$ 。

4.2.2 移动行为模式知识检索

在完成移动行为知识库 $\mathcal{R}$ 的构建后, 在线预测阶段通过模式级语义匹配机制引入先验知识。该过程不再对全量历史轨迹进行检索, 而是基于模式中心嵌入进行高效相似度匹配, 实现从群体行为模式中获取情境相关的经验支撑。首先, 对目标用户的查询轨迹 S_u^{query} 进行文本化表示。利用与知识库构建阶段一致的自然语言模板Prompt($\cdot$), 将当前轨迹转换为包含时间结构、空间转移及POI功能语义的行为描述。随后, 通过同一LLM编码器提取语义嵌入表示 $\mathbf{e}_u^{query}$ 。在语义空间中, 计算查询向量与各行为模式簇中心嵌入向量 $\mathbf{c}_k$ 的余弦相似度:

$$\text{sim}(\mathbf{e}_u^{query}, \mathbf{c}_k) = \frac{\mathbf{e}_u^{query} \cdot \mathbf{c}_k}{\|\mathbf{e}_u^{query}\| \|\mathbf{c}_k\|}。 \quad (3)$$

该相似度用于衡量当前移动行为与不同模式之间的语义接近程度。选择相似度最高的模式簇 C_{k^*} 作为当前情境下最相关的行为模式。最后, 从知识库中调用对应模式簇的语义摘要信息及其结构描述, 形成辅助知识上下文 $\mathcal{C}_{rag}$ 。该上下文刻画了在相似情境下群体层面的典型移动趋势与功能转移规律, 并作为外部先验融入后续LLM推理过程, 引导模型在语义空间中进行更加结构一致的决策。

4.3 引力搜索模块

引力搜索模块旨在为纯语义驱动的大语言模型引入物理知识的空间约束 (Spatial Constrain), 通过量化地理位置间的物理吸引力来约束预测空间。尽管大语言模型在推断用户意图方面表现出色, 但其缺乏对物理距离和空间可达性的感知, 容易生成虽然语义合理但地理上不可达的预测。如图3所示, 本模型基于引力模型构建了一个衡量当前位置到候选位置移动倾向性的评分系统, 从而生成地理上合理且具备功能吸引力的候选位置集合, 为后续




图3 引力搜索模块, 在搜索半径内基于距离与POI数量计算候选位置吸引力分数, 并通过对数平滑与排序筛选生成候选位置集合

移动预测提供可靠的搜索空间。

4.3.1 空间吸引力建模

为刻画位置间的空间相互作用关系, 本文采用改进的引力模型量化候选位置对用户的吸引力。模型假设地点吸引力与其功能设施 (POI) 丰富度成正比, 与两地之间的物理距离成反比。对于当前位置 l_i 与候选位置 l_j , 其在第 k 类POI上的吸引力分数定义为:

$$Score_{j,k} = \frac{N_{j,k}}{(D(l_i, l_j) + \beta)^\alpha}, \quad (4)$$

其中, $N_{j,k}$ 表示位置 l_j 区域内第 k 类POI数量, 反映该地点的功能强度; $D(l_i, l_j)$ 为两位置之间的地理距离; 幂函数刻画移动意愿随距离增加而产生的非线性衰减效应。参数 α 与 β 通过历史轨迹数据进行统计拟合获得。其中, α 控制距离衰减强度, 刻画长距离移动阻力; β 用于平滑短距离区域的衰减曲线, 避免分母趋近于零。通过数据驱动拟合, 该模型能够反映特定城市环境中的空间移动规律, 并为后续预测提供可量化的结构约束。

4.3.2 候选筛选机制

为在大规模空间位置中构建结构合理的候选集合, 引力模块采用“搜索-评分-排序”流程。首先, 基于半径 r 执行范围搜索, 仅保留满足 $D(l_i, l_j) \leq r$ 的候选位置, 以保证地理可达性并降低计算复杂度。在限定搜索范围后, 对每个候选位置 l_j 在各POI类别下计算吸引力分数。考虑到城市POI分布呈长尾结构, 直接使用原始分数可能导致结果过度集中于少数高密度区域, 因此对其进行对数平滑处理:

$$Score'_{j,k} = \ln(1 + Score_{j,k})。 \quad (5)$$

该处理在保持相对排序关系的同时压缩极端数值差异。最终, 模块根据平滑分数 $Score'_{j,k}$ 对每个类别下的候选地点进行排序, 并选取Top-N个位置组成最终的下一位置候选集 (Next Location Candidates):

$$\mathcal{L}_{cand} = \bigcup_{k=1}^K \{l_j \mid \text{Rank}(Score'_{j,k}) \leq N\}。 \quad (6)$$

这些候选位置不仅在地理距离上是可达的, 而且在特定功能类别上具有高吸引力。该候选集随后被




图4 移动行为预测模块,在检索到相似移动模式后,结合当前轨迹与候选位置,通过LLM进行语义推理与综合评估,最终确定用户下一位置。

输入大语言模型,作为Prompt的一部分或搜索空间剪枝的依据,极大地缩减了LLM的推理范围,使其能够专注于分析这些“物理可行”选项中的“语义最优”解,从而显著提升了预测结果的真实可靠性。

4.4 移动行为预测模块

移动预测模块作为整个框架的决策中枢,通过整合多源上下文信息,充分利用大语言模型的语义分析与逻辑推理能力,提取用户出行意图并输出移动预测结果。如图4所示,不同于传统移动行为预测模型侧重于基于神经网络或注意力机制的数值拟合,本模块的核心在于将异构的时空特征语义化,通过精细设计的提示工程(Prompt Engineering),构建了一条大语言模型可解析的自然语言逻辑链。这种方法模拟了人类的认知推理过程,使其能够依据背景知识和逻辑判断进行决策。

4.4.1 多源信息整合

我们构建了一个集成了多维视角的综合推理提示词Prompt($\cdot$),使大语言模型能够处理多模态的时空输入。提示词将不同层次的信息进行了结构化的语义翻译。首先,对于用户的历史移动轨迹 $\mathcal{S}_u$,我们列出了途经点序列,还通过POI数据库注入了每个位置的核心功能属性,例如餐饮与办公,并以自然语言显式描述了相邻位置间的实际移动距离,从而强化模型对移动成本和个人偏好的感知。其次,提示词中嵌入了由RAG模块生成的群体模式摘要 $\mathcal{C}_{rag}$,这部分信息提供了高层的行为指导,例如相似群体在此时段倾向于返回居住区。最后,引力模块计算出的包含吸引力分数与物理距离的Top-N候选位置列表 $\mathcal{C}_{grav}$ 也被纳入其中,为模型提供了明确的物理约束参考。这种跨模态的信息整合过程可以用形式化公式表示为:

$$\hat{l}_{t+1} = \text{LLM}_{pred}(\text{Prompt}(\mathcal{S}_u, \mathcal{C}_{rag}, \mathcal{L}_{cand})), \quad (7)$$

其中, $\text{Prompt}(\cdot)$ 表示预设的指令模板, $\mathcal{S}_u$ 表示用户历史轨迹序列, $\mathcal{C}_{rag}$ 代表从群体数据中提取的共性知识摘要,而 $\mathcal{L}_{cand}$ 则是结合了物理引力与功能

吸引力筛选出的候选位置集合。通过这种方式,微观的个人习惯、宏观的群体规律以及硬性的物理限制被统一映射到了同一语义平面上,为后续的推理提供了完整的信息基础。

4.4.2 移动决策推理

在此基础上,大语言模型执行深度推理过程,模拟人类的复杂决策思维。在接收到整合后的信息后,模型展开了一个多阶段的认知推理过程。大语言模型首先会深度分析用户的历史轨迹文本,识别用户当前的出行意图与状态,例如判断用户是否正处于从办公区离开的下班途中。紧接着,模型会参考RAG提供的群体规律摘要,验证这一意图是否符合常规时空模式,并利用群体共性知识填补个体数据稀疏带来的信息缺口。随后,在决策阶段,模型会在引力模块提供的物理可行候选集中进行筛选。这一过程类似于人类在面对多个选择时的权衡:模型不仅考虑候选地点的功能吸引力分数,还会结合物理距离进行综合评估,并依据前序步骤推断出的语义意图判断哪个候选点最符合当前的移动逻辑。例如,模型可能推理出尽管某商业区吸引力很高,但考虑到距离因素以及当前归家模式的语义语境,居住区是更为合理的下一站选择。最终,大语言模型将这些隐式的推理过程转化为显式的预测结果,直接生成下一时刻的预测位置ID,从而实现了语义智能与物理规律在决策层面的深度协同。

5 实验设置

在本节中,我们将详细介绍用于评估模型的三个真实世界数据集及预处理方法,阐述实验的具体设置与评价指标。

5.1 数据集

为了验证本研究提出模型的预测表现,我们选取了三个具有代表性的真实世界数据集:北京数据集、深圳数据集和南昌数据集。这些数据集涵盖了不同规模的城市形态及多样化的移动模式。具体而言,北京数据集(ChinaMobile) [27]采集自当地移动运营商,记录了用户连接附近蜂窝基站的时间与位置,反映了大规模人群在城市中的移动规律;深圳数据集(Private Car Trip) [4]记录了私家车的出发位置、停止位置及时间戳,通过车辆的行驶轨迹反映了驾驶用户的移动行为;南昌数据集(Mobile Applications Usage) [24]记录了用户在使用手机应用(App)时的时间戳及其对应的基站位置,能够捕捉用户与数字服务交互时的移动特征。为了消除原始传感器数据的噪声并将连续轨迹转化为模型可处理的离散序列,我们统一执行了标准化的预处理流程。在时间维度上,我们将时间轴标准化,以30分钟为间隔进行离散化处理。

表1 数据集统计特征

数据集	城市	收集时间	研究范围(°)	用户数	记录数
手机GPS数据集	北京	2022.07.05 - 2022.08.31	(116.31,39.84)-(116.47,40.00)	3,818	8,979,770
私家车出行数据集	深圳	2022.07.31 - 2022.08.31	(114.02,22.51)-(114.18,22.67)	5,438	4,385,963
应用使用数据集	南昌	2022.05.18 - 2022.05.25	(115.78,28.58)-(115.94,28.74)	3,604	2,833,191

此外, 为了增强地理语义理解, 我们收集了各城市对应的兴趣点 (POI) 数据。参考通用分类标准, 我们将POI划分为14个大类。我们统计了每个网格内各类POI的数量与占比分布, 作为构建语义提示词和引力吸引力计算的基础数据。表1展示了各数据集的详细统计信息。

5.2 参数设置

所有用户随机打乱后按照70%:15%:15%的比例被划分为训练集、验证集和测试集。其中, 我们在训练集上构建检索增强生成的历史轨迹知识库以及拟合引力模型的参数。我们将历史观测窗口长度 (Obs.len) 设置为12个时间步, 即利用用户过去6小时的轨迹信息, 预测窗口长度 (Pred.len) 设置为1个时间步, 即预测下一时刻的用户位置。本研究中各关键模块的超参数设置如下: 首先, 在RAG模块的知识库构建阶段, 我们利用HDBSCAN聚类算法得到训练集中的代表性轨迹簇, 并采用中心边缘混合采样策略选取代表性样本, 最终构建检索数据库。在推理阶段, 我们检索Top-10 ($m = 10$) 个最相似的历史轨迹作为辅助上下文。其次, 在Gravity模块中, 为了平衡计算效率与候选覆盖率, 我们将物理空间的搜索半径设置为5km。最后, 在大语言模型设置方面, 我们选用Gemma-2-9B作为基座模型。所有训练与推理任务均在单张NVIDIA A100 40GB GPU 上完成。

5.3 评价指标

为了全面评估模型的预测性能, 我们采用了以下三个广泛使用的评估指标:

(1) **Top-K 准确率 (Accuracy, Acc@K)**: 该指标衡量真实位置 (Ground-truth) 出现在模型前 K 个预测结果列表中的比例。在本实验中, 我们将 K 设为1, 3 和5。其定义如下:

$$Acc@K = \frac{\#hit@K}{|N_{test}|}, \quad (8)$$

其中 $\#hit@K$ 表示测试集中真实位置出现在前 K 个预测结果中的样本数量, $|N_{test}|$ 表示测试集样本总数。

(2) **平均倒数排名 (Mean Reciprocal Rank, MRR@K)**: MRR 更关注真实位置在预测列表中的排名先后, 排名越靠前得分越高。计

算公式如下:

$$MRR@K = \frac{1}{|N_{test}|} \sum_{i=1}^{|N_{test}|} rank_i, \quad (9)$$

其中 $rank_i$ 是第 i 个预测中真实位置排名的倒数 (Reciprocal of the rank)。如果真实位置未出现在前 K 个预测结果中, 则该项为0。

(3) **平均位移误差 (Average Displacement Error, ADE)**: ADE 用于评估模型预测位置与真实位置之间的物理距离偏差 (单位: 公里)。我们计算Top-1 预测位置的坐标与真实位置中心坐标之间的欧氏距离或Haversine 距离:

$$ADE = \frac{1}{|N_{test}|} \sum_{i=1}^{|N_{test}|} Dist(\hat{l}_{top1}^{(i)}, l_{gt}^{(i)}). \quad (10)$$

较低的ADE 值表明模型具有更好的空间精确度。

5.4 基线方法

为了全面评估所提出框架的性能, 我们选取了以下具有代表性的基准模型进行对比, 涵盖了从经典的物理模型、序列推荐算法、深度学习模型到最新的大语言模型方法:

(1) **Gravity [16] (Adapted Gravity Model, 自适应引力模型)**: 一种改进的数据驱动引力模型。该模型显式地在训练数据上拟合目的地吸引力和距离衰减参数, 建立了一个针对当前数据集特征的空间交互基线。

(2) **FPMC [20] (Factorizing Personalized Markov Chains, 因子化个性化马尔可夫链)**: 一种经典的个性化序列推荐模型。该模型结合了用户特定的潜在偏好与一阶马尔可夫转移动态, 用于捕捉序列数据中的个性化与短期转移特征。

(3) **DeepMove [21] (DeepMove, 深度移动预测模型)**: 一种基于注意力机制的循环神经网络移动预测模型。该模型通过对历史轨迹进行注意力建模, 能够同时捕捉用户移动行为中的长期周期性模式与短期序列模式。

(4) **STHGCN [23] (Spatio-Temporal Hypergraph Convolutional Network, 时空超图卷积网络)**: 一种基于超图神经网络的方法。该模型通过多关系消息传递机制, 显式地建模POI之间的高阶时空依赖关系, 以提升预测性能。

(5) **LLM-ZS** [10] (Large Language Models are Zero-Shot Next Location Predictors, 大语言模型零样本下一位置预测器): 一种零样本预测基线。该方法将下一位置预测形式化为自然语言推理任务, 直接利用预训练的大语言模型进行推理, 无需进行针对特定任务的训练。

(6) **LLM-COD** [11] (Large Language Model Conditioned Origin-Destination Prediction, 大语言模型条件起讫点预测): 一种基于大语言模型的条件预测方法。该方法以结构化的上下文描述为条件, 并在候选位置集合上执行约束解码以预测目的地。

(7) **AgentMove** [12] (Agentic Framework for Zero-shot Next Location Prediction, 基于智能体的零样本移动预测框架): 一项最新的基于智能体 (Agent) 的零样本预测框架。该框架利用大语言模型作为核心控制器, 通过整合语义推理能力与外部移动先验知识来执行下一位置预测。

6 实验结果与分析

在本节中, 我们将分别从基线对比、消融研究、参数实验、案例分析、基座模型实验、泛化研究、知识库分析多个方面, 对模型性能展开全面的实验分析, 验证模型在跨城市场景下的泛化能力, 并深入剖析检索知识库的规模与构建策略对系统性能的贡献。

6.1 移动行为预测性能分析

本节旨在通过与多种现有主流方法进行对比, 全面评估RAG²-MP模型在真实世界移动预测任务上的性能表现。表2详细列出了所有对比模型在北京、深圳和南昌三个不同城市规模数据集上的实验结果。观察表中的数据可以发现, 我们的模型 (RAG²-MP) 在所有评估指标 (Acc@K, MRR@K, ADE) 以及所有数据集上均取得了最优结果, 这证明了所提方法的有效性与鲁棒性。具体而言, 在Acc@1指标上, 我们的模型表现最好。相较于次优的基线模型LLM-COD, 我们的模型在三个数据集上的平均准确率从0.5130提升至0.5644, 提升幅度达到了10.02%。特别是在深圳数据集上, 我们的Acc@1更是高达0.6068 (对比基线的0.5491)。在衡量Top-K推荐质量的Acc@3、Acc@5以及关注排名顺序的MRR@5指标上, 我们的模型同样有着更好的表现。以Acc@5为例, 我们的模型平均达到了0.6469, 相比基线提升了11.32%; MRR@5平均得分0.5889, 提升了8.91%。这些指标反映了模型在提供多样化且高质量候选列表方面的能力, 这主要得益于RAG模块的关键作用。RAG通过检索与当前查询最相似的历史轨迹, 有效地提炼出了用户在特定情境下的通用出行模式与长尾偏好。这些检

索到的外部知识作为参考上下文, 极大地丰富了模型的输入信息, 使得模型即使在Top-1预测未命中的情况下, 也能将真实位置包含在靠前的预测列表中, 从而提升了系统的容错率。

在衡量物理空间距离误差的ADE指标上, 我们的模型有很大的提升。ADE值越低代表预测位置与真实位置的空间距离越近。我们的模型在三个数据集上的平均ADE仅为1.3067km, 相比于LLM-ZS (4.2552km) 和STHGCN (4.0695km) 等未充分利用地理约束的方法, 误差大幅降低。即使与同样表现优秀的LLM-COD (1.4425km) 相比, 我们也取得了9.41%的改进。这一优异表现主要归功于Gravity模块的作用。引力模型引入了明确的地理物理知识, 严格约束了LLM的搜索和预测范围, 排除了那些语义可能相关但地理上不可达或不合理的候选点。这种物理约束通过过滤机制增强了模型的空间理解能力, 确保了预测结果在地理空间上的精确性与合理性。模型整体在预测任务表现上的显著提升还归功于基座大语言模型本身强大的语义分析、理解与推理能力。通过精心设计的Prompt工程, LLM能够深入理解用户的移动意图, 并结合上下文信息做出精准的决策, 从而在直接命中真实目的地的能力上远超传统的深度学习模型。

6.2 模块消融实验分析

为深入探究本研究提出的移动预测框架中各关键组件的有效性与贡献, 我们设计了消融实验, 分别评估了移除引力模型 (w/o Gravity) 和移除检索增强模块 (w/o RAG) 后的模型表现。这两个变体。具体而言: (1) **w/o RAG**: 该变体移除了检索增强生成模块, 模型在推理时不再检索相似的历史轨迹作为上下文参考, 旨在验证外部历史知识对捕捉个性化移动模式的贡献; (2) **w/o Gravity**: 该变体移除了引力模型组件, 取消了基于地理距离与POI吸引力的候选点筛选机制, 旨在评估物理空间约束对提升预测合理性与精确度的必要性。对比了模型在削减这些关键模块后的性能变化。表3展示了详细的实验结果, 数据显示我们的完整模型 (RAG²-MP) 在所有指标上均显著优于其他变体, 证明了融合物理规律与历史上下文的必要性。

具体而言, 通过对比w/o RAG 与RAG²-MP 的结果可以发现, 移除历史轨迹检索机制后, 模型在准确率指标上出现了大幅下滑。以北京数据集为例, Acc@1 从0.5510 下降至0.4592, 降幅约为16.6%; 同时MRR@5 从0.5886 下降至0.5437。这一显著差距表明, 对于测试集中未见过的用户 (Unseen Users), RAG 模块起到了至关重要的知识补充与类比示范作用。由于模型无法直接访问

表2 基准模型之间的评价指标结果对比

指标	数据集	Gravity	FPMC	DeepMove	STHGCN	LLM-ZS	LLM-COD	AgentMove	RAG ² -MP
Acc@1	北京	0.3776	0.3061	0.4184	0.4359	0.4122	<u>0.4997</u>	0.4499	0.5510
	深圳	0.4068	0.4008	0.5043	0.4930	0.5026	<u>0.5491</u>	0.4274	0.6068
	南昌	0.4179	0.4188	0.4500	0.4411	0.4150	<u>0.4902</u>	0.4877	0.5353
	Average (↑)	0.4008	0.3752	0.4576	0.4567	0.4433	<u>0.5130</u>	0.4550	0.5644 (10.02%)
Acc@3	北京	0.5327	0.4694	0.5216	0.4774	0.4531	0.5308	<u>0.5310</u>	0.5918
	深圳	0.5496	0.5036	0.5726	0.5335	0.5197	<u>0.5787</u>	0.5726	0.6325
	南昌	0.5136	0.5299	<u>0.5500</u>	0.4874	0.4500	0.5388	0.5419	0.5884
	Average (↑)	0.5320	0.5010	0.5481	0.4994	0.4743	<u>0.5494</u>	0.5485	0.6042 (9.97%)
Acc@5	北京	0.5543	0.5102	0.5816	0.5071	0.4633	0.5876	<u>0.5961</u>	0.6735
	深圳	0.5838	0.5393	0.5726	0.5373	0.5203	<u>0.6003</u>	0.5897	0.6633
	南昌	0.5493	0.5299	<u>0.5857</u>	0.5042	0.4601	0.5554	0.5547	0.6039
	Average (↑)	0.5791	0.5265	0.5800	0.5162	0.4812	<u>0.5811</u>	0.5802	0.6469 (11.32%)
MRR@5	北京	0.5172	0.3932	0.4915	0.4719	0.4313	<u>0.5359</u>	0.5216	0.5886
	深圳	0.5344	0.4531	0.5356	0.5134	0.5083	<u>0.5663</u>	0.5010	0.6199
	南昌	0.5006	0.4729	0.5032	0.4651	0.4323	<u>0.5200</u>	0.5083	0.5583
	Average (↑)	0.5174	0.4397	0.5101	0.4835	0.4573	<u>0.5407</u>	0.5103	0.5889 (8.91%)
ADE	北京	0.9818	2.4835	2.0072	3.3037	3.8848	<u>0.9802</u>	1.2793	0.8919
	深圳	1.5400	2.3597	2.5448	4.2203	4.1101	<u>1.4957</u>	3.6438	1.3490
	南昌	1.8518	2.4053	2.0682	4.6845	4.7706	<u>1.8516</u>	2.9984	1.6791
	Average (↓)	1.4579	2.4162	2.2067	4.0695	4.2552	<u>1.4425</u>	2.6405	1.3067 (9.41%)

新用户的长期历史偏好, RAG 通过检索知识库中具有相似时空特征的轨迹片段, 为大语言模型提供了类似场景下的群体移动模式作为参考。这种基于实例的上下文增强机制 (Example-based Context Enhancement) 使模型能够借鉴普遍的移动规律来推断当前用户的意图, 从而大幅提升了预测的准确性。其次, 对比w/o Gravity 与RAG²-MP 的表现, 最显著的差异体现在平均位移误差 (ADE) 指标上。在缺乏物理引力约束的情况下, 北京数据集的ADE 从0.8919km 激增至1.9854km, 误差扩大了1.2 倍以上; 在深圳和南昌数据集中也观察到了类似的趋势。这一结果清楚地说明, 仅依靠语义理解而不考虑地理空间距离的衰减效应, 容易导致模型预测出距离真实位置较远的目标。引力模块通过筛选地理上合理的候选区域, 有效地约束了预测结果, 极大地增强了模型的空间感知能力。

6.3 超参数性能影响分析

本节我们在北京和深圳两个数据集上分析了模型中两个关键超参数对预测性能的影响: RAG模块中检索历史相似样本的数量 (M) 以及Gravity模块中的搜索半径 r 。


(1)为了探究检索样本数量对模型性能的影响, 我们在范围[1, 15] 内调整检索样本数量 M ,

表3 各模块消融实验结果对比

数据集	模型变体	Acc@1	Acc@3	Acc@5	MRR@5	ADE
北京	w/o Gravity	0.3673	0.5714	0.6327	0.4793	1.9854
	w/o RAG	0.4592	0.5720	0.6633	0.5437	0.9619
	RAG ² -MP	0.5510	0.5918	0.6735	0.5886	0.8919
深圳	w/o Gravity	0.4786	0.6154	0.6239	0.5430	2.6959
	w/o RAG	0.5897	0.6239	0.6367	0.6007	1.3550
	RAG ² -MP	0.6068	0.6325	0.6633	0.6199	1.3490
南昌	w/o Gravity	0.4179	0.5214	0.5321	0.4968	2.7732
	w/o RAG	0.4750	0.5286	0.5429	0.5044	1.7290
	RAG ² -MP	0.5353	0.5884	0.6039	0.5583	1.6791

相关的实验结果如图5所示。观察结果可知, 随着检索样本数量的增加, 模型的预测性能呈现先上升后下降的趋势, 并在 $M = 10$ 时达到最大值。这一现象表明, 增加适当数量的检索样本能够为模型提供更多有价值的信息, 有助于挖掘出更全面、共性的群体移动模式; 然而, 过多的检索样本会引入噪声, 稀释关键信息, 导致移动特征变得模糊, 从而导致模型表现下降。

(2)为了探究引力搜索范围对模型性能的影响, 我们将引力模型的物理搜索半径 r 设定在1km 到8km 之间进行分析, 结果如图5所示。模型性能随着搜索范围的扩大表现出先升后降的态势, 在半径为5km 时表现最好。这一结果说明, 扩大引力范



(a) 检索样本数量超参实验 (北京) (b) 检索样本数量超参实验 (深圳) (c) 引力搜索范围超参实验 (北京) (d) 引力搜索范围超参实验 (深圳)

图5 检索样本数量 M 与搜索半径 r 对模型性能的影响

推理Prompt
你的任务 (Task): 你是移动预测专家。基于当前轨迹、历史相似移动模式以及候选地点, 预测用户的下一个位置。 当前轨迹 (Query Mobility): 08:00 Grid 101 (商务住宅, 生活服务) -> 6.20km -> 09:00 Grid 303 (公司企业, 金融机构) -> 0.52km -> 12:00 Grid 305 (餐饮美食, 休闲娱乐) 相似移动特征 (RAG Summary): 移动模式: 历史相似轨迹强烈暗示了一种“回流”模式, 处于典型的工作日午餐行程中, 隐含了用户将在午餐结束后返回工作岗位的意图, 下一个动作是返回原工作地点。 下一位置类型: 公司企业、金融机构 空间特征: 观测到的转移模式主要是以办公地点为中心的短距离往返移动, 平均移动距离为0.57km。 停留倾向: 相似轨迹倾向于移动而非停留。 候选位置 (Candidates): 公司企业: Grid 303, 0.52km, 吸引力0.88、Grid 278, 0.76km 吸引力0.42、Grid 345, 3.66km, 吸引力0.53; 餐饮美食: <candidates>; 购物消费: <candidates>, 输出要求 (Output Format): 返回一个 JSON 对象, 包含 Grid_ID:<Number> 和 "Reason":<Text>。
推理结果Response
Grid_ID: 303 Reason: 综合分析用户的当前状态与历史模式: 1. 意图匹配: RAG分析指出的“工作-午餐-工作”回流模式与当前轨迹高度吻合。用户刚在Grid 305完成午餐, 最自然的下一步是返回上午的驻留点Grid 303继续工作。2. 类别一致性: RAG建议的下一地点类别为“公司企业”。3. 引力模型验证: Grid 303虽然有一定的物理距离(0.52km), 但其引力得分(0.88)高于其他办公或金融区域。因此, 预测结果为Grid 303。

图6 推理过程案例分析

围最初能够有效增加预测正确位置的可能性, 但过大的检索范围会导致引入大量可能的干扰选项, 不能正确反映出行的距离约束, 增加了决策难度。

6.4 推理过程案例分析

为了直观展示模型是如何利用外部知识库与物理约束进行推理的, 我们选取了一个典型的“工

作-午餐-工作”回流移动场景进行可视化分析, 如图6所示。在该案例中, 用户上午从商务住宅区 (Grid 101) 出发前往公司 (Grid 303), 随后在中午短距离移动至餐饮区域 (Grid 305) 就餐。在午餐后移动意图的推测中, 我们的模型展现了阶段性的推理过程。首先, RAG模块检索到的历史相似轨迹反映了一种共性的回流模式。模型分析指出, 这种处于工作日午餐行程的上下文, 隐含了用户在午餐结束后返回工作岗位的意图, 明确了下一个动作应是“返回原工作地点”。其次, 结合Gravity模块生成的候选列表, LLM进行了多维度的验证。首先是类别一致性, RAG建议的下一地点类别为“公司企业”, 直接指向了候选列表中的Grid 303。其次是引力模型验证, 尽管Grid 303距离当前位置有一定物理距离 (0.52km), 但其引力得分 (0.88) 远高于其他候选区域 (如Grid 278的0.42)。最终, 综合“工作-午餐-工作”的语义回流模式与高引力得分, 模型成功排除了其它干扰, 精准预测用户将返回上午的驻留点Grid 303继续工作。这一过程证明了所提框架通过结合显式的语义意图推理与量化的物理引力约束, 能够有效解决复杂场景下的用户意图理解与位置预测问题。

6.5 基座模型选择分析

本节旨在探讨基座大语言模型 (LLM Backbone) 的选择对预测性能的影响。我们对比了Gemma-2、Llama-2和Qwen-3三个主流系列的多种不同参数规模的模型, 图7展示了各模型在北京数据集上的详细表现。实验结果表明, 基座模型的参数规模与预测性能呈现明显的正相关关系。在同一模型系列中, 如从Gemma-2-2B到9B, 或从Llama-2-7B到13B, 随着参数量的增加, 模型在准确率和位移误差等各项指标上均有显著提升。这证明了更大规模的模型通常具备更强的语义理解与逻辑推理能力, 能够更有效地处理复杂的时空上下文信息。尽管Llama-2-13B在Acc@1等指标上取得了最高分, 但Gemma-2-9B在Acc@5上表现更优且计算开销相对较低, 综合考虑性能与效率, 本研究最终选择Gemma-2-9B作为默认基座模型。




图7 不同基座大语言模型在北京数据集上的性能对比

6.6 跨城市泛化性分析

为了验证本模型的跨城市泛化能力，特别是检验RAG模块中历史轨迹知识库的可迁移性与扩展性，我们设计了跨城市泛化实验。具体而言，我们将在源城市（Source City）数据集上构建的历史轨迹知识库，直接应用于目标城市（Target City）的移动预测任务中，以评估知识库在不同城市环境下的适用性。图8展示了泛化实验的结果，其中底部表示用于构建知识库的源城市，左侧表示进行预测的目标城市。从实验结果可以观察到，即使将某一城市的知识库应用于其他城市的预测任务，模型性能并未出现显著下降。例如，使用深圳知识库在北京数据集上的预测准确率仅比使用北京本地知识库略低2-3个百分点，ADE略低0.02km。这一现象表明，本地知识库更能反映该城市的特定移动特征的同时，不同城市的人类移动模式在宏观层面具有一定的共性和规律性，RAG模块能够有效捕捉这些通用的时空行为模式，使得构建的知识库具有良好的跨域迁移能力。总体而言，实验结果充分证明了本模型的泛化能力，为在数据稀缺的新城市快速部署提供了可能性。

6.7 知识库扩展性分析

为了深入探究RAG模块中历史轨迹知识库的规模扩展性对模型性能的影响，我们设计了知识库配置实验。具体而言，我们对比了四种不同的知识库构建策略：(1)不使用RAG模块，即无知识库支持；(2)仅使用目标预测城市本身的训练数据构建知识库；(3)使用除目标城市外的另外两个城市的数据联合构建知识库；(4)融合所有三个城市的训练数据构建统一的大规模知识库。表4展示了不同知识库配置策略在三个数据集上的详细实验结果。从数据中可以观察到，使用本地城市知识库相比不使用知识库能够带来显著的性能提升，这再次验证了检索增强机制的有效性。值得注意的




图8 跨城市泛化实验结果热力图。行表示用于构建知识库的源城市，列表示进行预测的目标城市

表4 不同知识库配置策略的性能对比

数据集	知识库来源	Acc@1	Acc@3	Acc@5	MRR@5	ADE
北京	不使用	0.4592	0.5720	0.6633	0.5437	0.9619
	北京	0.5510	0.5918	0.6735	0.5886	0.8919
	深圳& 南昌	0.5576	0.5919	0.6790	0.5956	0.8823
	所有城市	0.5711	0.6013	0.6952	0.6009	0.8788
深圳	不使用	0.5897	0.6239	0.6367	0.6007	1.3550
	深圳	0.6068	0.6325	0.6633	0.6199	1.3490
	北京& 南昌	0.6059	0.6308	0.6602	0.6199	1.3510
	所有城市	0.6194	0.6489	0.6694	0.6311	1.3271
南昌	不使用	0.4750	0.5286	0.5429	0.5044	1.7290
	南昌	0.5353	0.5884	0.6039	0.5583	1.6791
	北京& 深圳	0.5409	0.5950	0.6189	0.5715	1.6700
	所有城市	0.5651	0.6038	0.6277	0.5853	1.6509

是，使用其他两个城市构建的知识库同样能够取得接近甚至略优于本地知识库的表现，这进一步证实了人类移动模式的跨域通用性。更重要的是，融合所有城市数据构建的统一知识库在所有指标上均取得了最优结果，例如在北京数据集上，Acc@1从单城市的0.5510提升至0.5711，ADE从0.8919km降至0.8788km。这表明扩大知识库规模能够覆盖更多样化的移动模式，为模型提供更丰富的参考样本，从而进一步提升预测性能。该实验充分证明了本框架具备良好的知识库扩展能力，支持通过整合多源数据来构建更强大的通用预测系统。

此外，为了更直观地展示不同知识库策略对预测结果的具体影响，我们利用热力图对北京数据集上的真实值和预测分布进行了可视化分析。如图9所示，(a)展示了测试集用户的真实出行热力分布；(b)是未使用知识库时的预测分布，可以看出热点区域较为分散且与真实分布存在较大偏差，




图9 北京数据集测试样本在不同知识库配置下的预测结果可视化对比。

未能准确捕捉到主要的人群聚集模式；(c)展示了引入北京本地知识库后的结果，预测热力图的重点区域开始向真实分布靠拢，体现了同城历史模式的参考价值；(d)则展示了使用融合三个城市数据的全局知识库后的预测结果，其热力分布形态与真实分布最为接近，高频访问区域的覆盖度显著优于其他对照组。这一可视化结果印证了前述的定量分析结论，即随着知识库规模的扩大和信息的丰富，模型能够更精准地还原真实的人类移动空间分布特征。

7 总结

本文针对现有大语言模型在移动行为预测任务中存在的参数记忆静态化与空间感知缺失问题，提出了一种协同检索增强生成（RAG）与引力模型的移动行为预测框架RAG²-MP。该框架通过构建历史轨迹知识库并引入检索增强机制，实现了从“参数记忆”到“数据驱动推理”的方案转变，使模型能够灵活利用群体共性移动模式；同时，结合改进的引力模型显式建模POI吸引力与距离衰减规律，为语义驱动的LLM赋予了接地的物理空间约束。在三个真实世界数据集上的全面实验证明，所提模型在预测准确率、空间一致性及跨城市泛化能力上均显著优于现有最先进基线方法。未来的工作将重点关注以下两个方向：一是探索更加轻量化且隐私安全的检索机制，例如结合差分隐私技术构建去标识化的轨迹索引，以降低隐私泄露风险；二是研究多模态大语言模型在移动行为预测中的应用，尝试融合卫星图像、路网拓扑等多源异构数据，进一步提升模型对复杂城市环境的感知与推理能力，推动移动行为预测技术在智慧城市建设中的落地应用。

参考文献

- [1] 胥帅, 李博涵, 许建秋, 等. 意图感知的社交网络用户城外移动行为预测[J]. 计算机学报, 2024, 47(11): 2579-2593.
- [2] Zhang H, Dai L. Mobility prediction: A survey on state-of-the-art schemes and future applications. IEEE Access, 2018, 7: 802-822.
- [3] Ma Z, Zhang P. Individual mobility prediction review: Data, problem, method and application. Multimodal Transportation, 2022, 1(1): 100002.
- [4] Xiao Z, Liu B, Wu L, et al. Exploring spatio-temporal carbon emission across passenger car trajectory data. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(8): 9655-9669.
- [5] 徐丰力, 李勇. 城市环境下的用户移动行为建模概述[J]. 通信学报, 2020, 41(7): 135-149.
- [6] 姜涛, 徐胜华, 李晓燕, 等. 时空序列嵌入门控扩张残差网络的兴趣点推荐[J]. 武汉大学学报(信息科学版), 2024, 49(9): 1461-1470.
- [7] Han H, Zhang M, Hou M, et al. STGCN: A spatial-temporal aware graph learning method for POI recommendation //Proceedings of the 2020 IEEE International Conference on Data Mining (ICDM). Sorrento, Italy, 2020: 1052-1057.
- [8] Liu Z, Zhao C, Iandola F, et al. MobileLLM: Optimizing sub-billion parameter language models for on-device use cases //Proceedings of the 41st International Conference on Machine Learning (ICML). Vienna, Austria, 2024.
- [9] Du Y, Feng J, Zhao J, et al. TrajAgent: An LLM-based agent framework for automated trajectory modeling via collaboration of large and small models. arXiv preprint arXiv:2410.20445, 2024.
- [10] Beneduce C, Lepri B, Luca M. Large language models are zero-shot next location predictors. IEEE Access, 2025.
- [11] Yu C, Xie X, Huang Y, et al. Harnessing LLMs for cross-city OD flow prediction //Proceedings of the 32nd ACM International Conference on Advances in Geographic Information Systems. Atlanta, GA, USA, 2024: 384-395.
- [12] Feng J, Du Y, Zhao J, et al. AgentMove: A large language model based agentic framework for zero-shot next location prediction //Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics. 2025: 1322-1338.
- [13] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 2020, 33: 9459-9474.
- [14] 袁乐, 刘绍华, 王禹, 等. 大语言模型检索增强生成优化技术研究综述[J/OL]. 计算机学报, 2025.
- [15] Duddy E A. The law of retail gravitation. University of Chicago Press, 1932.
- [16] Converse P D. New laws of retail gravitation. Journal of Marketing, 1949, 14(3): 379-384.

- [17] Simini F, Barlacchi G, Luca M, et al. A deep gravity model for mobility flows generation. *Nature Communications*, 2021, 12(1): 6576.
- [18] Wang Z, Chen Y. Exploring spatial patterns of interurban passenger flows using dual gravity models. *Entropy*, 2022, 24(12): 1792.
- [19] Capoani L. Review of the gravity model: Origins and critical analysis of its theoretical development. *SN Business & Economics*, 2023, 3(5): 95.
- [20] Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing personalized Markov chains for next-basket recommendation // *Proceedings of the 19th International Conference on World Wide Web*. Raleigh, NC, USA, 2010: 811-820.
- [21] Feng J, Li Y, Zhang C, et al. DeepMove: Predicting human mobility with attentional recurrent networks // *Proceedings of the 2018 World Wide Web Conference*. Lyon, France, 2018: 1459-1468.
- [22] Feng J, Yang Z, Xu F, et al. Learning to simulate human mobility // *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. CA, USA, 2020: 3426-3433.
- [23] Yan X, Song T, Jiao Y, et al. Spatio-temporal hypergraph learning for next POI recommendation // *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. Taipei, Taiwan, 2023: 403-412.
- [24] Huang Z, Li T, Wang X, et al. Predicting mobile app usage with context-aware dynamic hypergraphs. *IEEE Transactions on Mobile Computing*, 2025.
- [25] Yang D, Qu B, Yang J, et al. Revisiting user mobility and social relationships in LBSNs: A hypergraph embedding approach // *Proceedings of the World Wide Web Conference*. San Francisco, CA, USA, 2019: 2147-2157.
- [26] Khaokaew Y, Xue H, Salim F D. Maple: Mobile app prediction leveraging large language model embeddings[J]. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2024, 8(1): 1-25.
- [27] Shao C, Xu F, Fan B, et al. Chain-of-planned-behaviour workflow elicits few-shot mobility generation in LLMs. *arXiv preprint arXiv:2402.09836*, 2024.



LIU Bo, M.S. His research interests include mobile computing and spatial intelligence.

LI Tong, Ph.D., Professor. His research interests include mobile computing and spatial intelligence.

XIAO Zhu, Ph.D., Professor. His research interests include intelligent information processing, Internet of Vehicles and wireless communications systems.

TANG Zhuo, Ph.D., Professor. His research interests include supercomputing and cloud computing, high-performance computing and artificial intelligence fusion computing.

LI Ken-Li, Ph.D., Professor. His research interests include high-performance computing system software and applications.

Background

Human mobility prediction belongs to the research area of urban computing and spatio-temporal data mining. The problem focuses on predicting the next location that a user will visit based on historical trajectory records and contextual information. Accurate mobility prediction plays an important role in intelligent transportation systems, location-based services, urban planning, and public safety management. With the rapid growth of mobile sensing devices and large-scale trajectory datasets, human mobility modeling has become an important research topic in recent years.

Existing studies mainly model mobility behavior through statistical models, physical interaction models, and deep learning approaches. Early research relied on probabilistic models such as Markov chains and spatial interaction models such as gravity models to describe movement transitions between regions. More recently, deep learning methods, including recurrent neural networks, attention-based models, and graph neural networks, have been widely adopted to capture complex spatial-temporal dependencies in trajectory data. These approaches significantly

improve prediction accuracy. However, most existing methods mainly learn numerical correlations from trajectory data and lack the ability to incorporate high-level behavioral knowledge and semantic reasoning. In addition, many models do not explicitly consider geographic interaction mechanisms, which limits the physical interpretability and spatial consistency of prediction results.

This study addresses these limitations by introducing a knowledge-enhanced mobility prediction framework named RAG²-MP. The proposed method establishes a collaborative framework that jointly leverages retrieval-augmented generation and spatial interaction modeling. Collective mobility patterns retrieved from historical trajectories provide contextual behavioral knowledge for the prediction process. Meanwhile, an improved gravity model captures spatial interaction relationships between locations based on geographic distance and point-of-interest distributions. Joint reasoning over contextual knowledge and spatial structure constraints enables the prediction model to generate results that remain both semantically meaningful and geographically consistent.

This research is supported by the National Natural Science Foundation of China (U24A20247, 62471277) and the Young Talent Support Program of the China Association for Science and Technology (ZB2025-29). The project aims to advance knowledge-driven mobility modeling methods for intelligent urban computing systems. Previous studies by the research group have investigated mobility pattern discovery, trajectory generation models, and knowledge-enhanced prediction methods. The work presented in this paper focuses on the integration of behavioral knowledge retrieval and spatial interaction modeling, which forms an important component of the overall research project on intelligent mobility behavior understanding and prediction.